




SVM-支持向量机

Support Vector Machine

- 提出时间:1964年
- 应用领域: 人像识别, 文本分类等模式识别问题中均有应用
- 当前标准的前身(软间隔)由Corinna Cortes和Vapnik于1993年提出, 并于1995年发表





SVM定义

- 是在分类与回归分析中分析数据的**监督式学习模型**与相关的学习算法。给定一组训练实例，每个训练实例被标记为属于两个类别中的一个或另一个，SVM训练算法创建一个将新的实例分配给两个类别之一的模型，使其成为**非概率二元线性分类器**。SVM模型是将实例表示为空间中的点，这样映射就使得单独类别的实例被**尽可能宽的明显的间隔**分开。然后，将新的实例映射到同一空间，并基于它们落在间隔的哪一侧来预测所属类别。



如何更好地分类？





超平面

- 在样本空间中，划分超平面可通过如下线性方程来描述：

$$\omega^T x + b = 0 \quad (6.1)$$

$\omega = (\omega_1; \omega_2; \dots; \omega_d)$ 为法向量，决定超平面的方向， b 为位移项，决定了超平面与原点的距离。



- 知道了法向量 ω 和位移 b 。
- 样本空间中任意一点 x 到超平面 (ω, b) 的距离可表示为:


$$\gamma = \frac{|\omega^T x + b|}{\|\omega\|} \quad (6.2)$$

$$\|\omega\|: \text{二阶范数} \\ = \sqrt{\omega^T \omega}$$

$$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}$$



支持向量与间隔



$$\begin{cases} \omega^T x_i + b > 0, & y_i = +1; \\ \omega^T x_i + b < 0, & y_i = -1; \end{cases}$$

- 支持向量与间隔:
- 超平面 (ω, b) 能将训练样本正确分类, 距离超平面最近的这几个训练样本点使式(6.3)成立:

$$\begin{cases} \omega^T x_i + b \geq +1, & y_i = +1; \\ \omega^T x_i + b \leq -1, & y_i = -1; \end{cases} \quad (6.3)$$

那么这几个样本点被称为“支持向量 (support vector)”，两个异类支持向量到超平面的距离之和称为间隔:

$$r = \frac{2}{\|\omega\|} \quad (6.4)$$

$$d = \frac{|c_1 - c_2|}{\sqrt{a^2 + b^2}}$$

$$\begin{cases} \omega^T x_i + b \geq +1, & y_i = +1; \\ \omega^T x_i + b \leq -1, & y_i = -1; \end{cases} \quad (6.3)$$

- 我们要找“最大间隔”的划分超平面，也就是要找能满足式(6.3)中约束的 ω, b , 使得间隔 r 最大，即

$$\max_{\omega, b} \frac{2}{\|\omega\|} \quad (6.5)$$

$$\text{s.t.} \quad y_i(\omega^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m$$

$$r = \frac{2}{\|\omega\|}$$

- 为求得最大间隔 r ，显然需要 $\|\omega\|$ 最小化，这等价于 $\|\omega\|^2$ 最小化。可以写成：

$$\min_{\omega, b} \frac{1}{2} \|\omega\|^2 \quad (6.6)$$

$$\text{s.t.} \quad y_i(\omega^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m$$

这就是支持向量机的基本型。



对偶算法

$$\begin{aligned} & \min_{\omega, b} \frac{1}{2} \|\omega\|^2 \quad (6.6) \\ & s.t. \quad y_i(\omega^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

- 为了求解线性可分支持向量机的最优化问题，将式（6.6）作为原始最优化问题，应用拉格朗日对偶性，通过求解对偶问题，得到原始问题的最优解，这就是线性可分支持向量机的对偶算法。对偶问题往往更容易求解，同时自然引入核函数，进而推广到非线性分类问题。

对偶问题

- 对式(6.6)使用拉格朗日乘子法可得到所求问题的“对偶问题”
- 拉格朗日乘子法构造规则：
 - 以约束方程乘以非负的拉格朗日乘子，然后从目标函数中减去

$$L(\omega, b, \alpha) = \frac{1}{2} \|\omega\|^2 - \sum_{i=1}^m \alpha_i (y_i(\omega^T x_i + b) - 1)$$

即:

$$\begin{aligned} L(\omega, b, \alpha) \\ = \frac{1}{2} \|\omega\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\omega^T x_i + b)) \quad (6.8) \end{aligned}$$

$$\alpha = (\alpha_1; \alpha_2; \dots; \alpha_m).$$



$$\begin{array}{ll} \min_{\omega, b} & \frac{1}{2} \|\omega\|^2 \quad (6.6) \\ \text{s. t.} & y_i(\omega^T x_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{array}$$

对偶问题

- 根据拉格朗日对偶性，原始问题（6.6）的对偶问题是极大极小问题：

- $\max_{\alpha} \min_{\omega, b} L(\omega, b, \alpha)$

要求得对偶问题的解，需要先求 $L(\omega, b, \alpha)$ 对 ω, b 的极小，再求对 α 的极大。



求 $\min_{\omega, b} L(\omega, b, \alpha)$

○ 计算 $L(\omega, b, \alpha)$ 分别对 ω 和 b 求偏导为零可得:

○ $\omega = \sum_{i=1}^m \alpha_i y_i x_i \quad (6.9)$

○ $0 = \sum_{i=1}^m \alpha_i y_i \quad (6.10)$

○ 将上面式(6.9)带入该问题的拉格朗日函数,利用(6.10)可得到式:

○ $\min_{\omega, b} L(\omega, b, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad (6.11)$

s. t $\sum_{i=1}^m \alpha_i y_i = 0$

$\alpha_i \geq 0, i = 1, 2, \dots, m.$

$$L(\omega, b, \alpha) = \frac{1}{2} \|\omega\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (\omega^T x_i + b)) \quad (6.8)$$
$$\alpha = (\alpha_1; \alpha_2; \dots; \alpha_m).$$



求 $\max_{\alpha} L(\omega, b, \alpha)$

- 求 $\min_{\alpha} L(\omega, b, \alpha)$ 对 α 的极大，即得到对偶问题

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad (6.11)$$

$$s.t \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$

将式(6.11)的目标函数由极大转换成极小，就得到了与之等价的对偶最优化问题，即：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^m \alpha_i$$

$$s.t \quad \sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, m.$$



$$\omega = \sum_{i=1}^m \alpha_i y_i x_i$$

$$b = y_j - \sum_{i=1}^m \alpha_i y_i x_i^T x_j$$

- 求解出 α 后，求出 ω 与 b 即可得到模型

$$\begin{aligned} f(x) &= \omega^T x + b \\ &= \sum_{i=1}^m \alpha_i y_i x_i^T x + b \end{aligned} \quad (6.12)$$

- 求解 α 需满足**KKT条件**，即要求：

$$\begin{cases} \alpha_i \geq 0; \\ y_i f(x_i) - 1 \geq 0; \\ \alpha_i (y_i f(x_i) - 1) = 0. \end{cases} \quad (6.13)$$

对于任意样本 (x_i, y_i) ，总有 $\alpha_i = 0$ 或 $y_i f(x_i) = 1$ ，若 $\alpha_i = 0$ ，则该样本不会在式(6.12)的求和中出现，也就不会对 $f(x)$ 有任何影响；若 $\alpha_i > 0$ ，则必有 $y_i f(x_i) = 1$ ，所对应的样本点位于最大间隔边界上，是一个支持向量。



KKT 条件

- 一般情况下，最优化问题会碰到以下三种情况：
- （1）无约束条件
- （2）等式约束条件
- （3）不等式约束条件
- 设目标函数 $f(x)$ ，等式约束为 $h(X)$,不等式约束为 $g(x)$

$$\begin{array}{ll}\min & f(X) \\ \text{s.t.} & h_j(X)=0 \quad j=1,2,\dots,p \\ & g_k(X)\leq 0 \quad k=1,2,\dots,q\end{array}$$

- 则我们定义不等式约束下的拉格朗日函数 L ，则 L 表达式为：
 - $L(X, \lambda, u) = f(X) + \sum_{j=1}^p \lambda_j h_j(X) + \sum_{k=1}^q u_k g_k(X)$



- 此时若要求解上述优化问题，必须满足下述条件（也是我们的求解条件）：

$$\left. \frac{\partial L}{\partial X} \right|_{X=X^*} = 0 \quad (1)$$

$$\lambda_j \neq 0, \quad (2)$$

$$u_k \geq 0, \quad (3)$$

$$\mu_k g_k(X^*) = 0 \quad (4)$$

$$h_j(X^*) = 0 \quad j=1,2,\dots,p \quad (5)$$

$$g_k(X^*) \leq 0 \quad k=1,2,\dots,q \quad (6)$$

这些求解条件就是KKT条件。(1)是对拉格朗日函数取极值时候带来的一个必要条件，(2)是拉格朗日系数约束（等式情况），(3)是不等式约束情况，(4)是互补松弛条件，(5)、(6)是原约束条件。



线性可分支持向量机学习算法

(1) 构造并求解约束最优问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

(2) 计算

$$\begin{aligned} \omega &= \sum_{i=1}^m \alpha_i y_i x_i \\ b &= y_j - \sum_{i=1}^m \alpha_i y_i x_i^T x_j \end{aligned}$$

(3) 求得分离超平面

$$\omega^T x + b = 0$$



例题：

- 现在有正例点 $x_1 = (3,3)^T$, $x_2 = (4,3)^T$, 负例点 $x_3 = (1,1)^T$, 应用前面的求解算法求线性可分支持向量机。



例 7.2 训练数据与例 7.1 相同. 如图 7.4 所示, 正例点是 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$, 负例点是 $x_3 = (1, 1)^T$, 试用算法 7.2 求线性可分支持向量机.

解 根据所给数据, 对偶问题是

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ &= \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, 3 \end{aligned}$$

解这一最优化问题. 将 $\alpha_3 = \alpha_1 + \alpha_2$ 代入目标函数并记为

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

对 α_1, α_2 求偏导数并令其为 0, 易知 $s(\alpha_1, \alpha_2)$ 在点 $\left(\frac{3}{2}, -1\right)^T$ 取极值, 但该点不满足约束条件 $\alpha_2 \geq 0$, 所以最小值应在边界上达到.

当 $\alpha_1 = 0$ 时, 最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$; 当 $\alpha_2 = 0$ 时, 最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$. 于是 $s(\alpha_1, \alpha_2)$ 在 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 达到最小, 此时 $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$.

这样, $\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例点 x_1, x_3 是支持向量. 根据式 (7.25) 和式 (7.26) 计算得

$$w_1^* = w_2^* = \frac{1}{2}$$

$$b^* = -2$$

分离超平面为

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$

分类决策函数为

$$f(x) = \text{sign}\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2\right)$$

■



$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \quad (6.11) \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

SMO 算法

- SMO的基本思路是先固定 α_i 之外的所有参数，然后求 α_i 上的极值。由于存在约束 $\sum_{i=1}^m \alpha_i y_i = 0$ ，若固定 α_i 之外的其他变量，则 α_i 可由其他变量导出。于是，SMO每次选择两个变量 α_i 和 α_j ，并固定其参数。这样，在参数初始化后，SMO不断执行如下两个步骤直至收敛：
 - 选取一对需要更新的变量 α_i 和 α_j ；
 - 固定 α_i 和 α_j 以外的参数，求解式(6.11)获得更新后的 α_i 和 α_j
- 完整的SMO算法包括两部分：
 - 求解两个变量的二次规划问题
 - 选择需优化变量的启发式方法



关于 α_i 和 α_j 的二次规划问题

- 仅考虑 α_i 和 α_j 时，式(6.11)中的约束可重写为:

$$\alpha_i y_i + \alpha_j y_j = c, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0, \quad (6.14)$$

其中

$$c = -\sum_{k \neq i, j} \alpha_k y_k \quad (6.15)$$

是使 $\sum_{i=1}^m \alpha_i y_i = 0$ 成立的常数.用

$$\alpha_i y_i + \alpha_j y_j = c$$

消去式(6.11)中的变量 α_j ，则得到一个关于单变量二次规划问题，仅有的约束是 $\alpha_i \geq 0$ ，不难发现，这样的二次规划问题具有闭式解，于是不必调用数值优化算法即可高效的计算出更新后的 α_i 和 α_j .

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i y_i (c - \alpha_i y_i) x_i^T x_j \quad (6.11) \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

选择 α_i 和 α_j 的启发式方法

- 选取的两变量所对应样本之间的间隔最大，这样的两个变量有很大的差别，与对两个相似的变量进行更新相比，对他们进行更新会使得目标函数的数值产生更大的变化。



偏移量 b 的计算

- 对任意支持向量 (x_s, y_s) 都有 $y_s f(x_s) = 1$,即

$$y_s \left(\sum_{i \in S} \alpha_i y_i x_i^T x_s + b \right) = 1, \quad (6.17)$$

两边同乘 y_s ,

$$y_s^2 \left(\sum_{i \in S} \alpha_i y_i x_i^T x_s + b \right) = y_s$$

因为 $y_s^2 = 1$

$$\left(\sum_{i \in S} \alpha_i y_i x_i^T x_s + b \right) = y_s$$

$$b = y_s - \sum_{i \in S} \alpha_i y_i x_i^T x_s$$

其中 $S = \{i | \alpha_i > 0, i = 1, 2, \dots, m\}$ 为所有支持向量的下标集.理论上,可
选取任意支持向量并通过求解式(6.17)获取 b ,但现实任务中常采用
一种更鲁棒的做法:使用所有支持向量求解的平均值

$$b = \frac{1}{|S|} \sum_{s \in S} \left(\frac{1}{y_s} - \sum_{i \in S} \alpha_i y_i x_i^T x_s \right). \quad (6.18)$$



总结

- SVM不像逻辑回归一样去拟合样本点，而是在样本中找分隔线，为了评判哪条分隔线最好，引入了几何间隔的概念。之后所有的推导都是去解决目标函数的最优问题上去了，为了更好地解决计算问题，引入了拉格朗日对偶问题，在引入拉格朗日对偶问题后消去了 ω ，把问题转换为计算 α ，使得优化函数变为拉格朗日乘子的单一优化问题。

